

MLOmega V18.8

Installation, lancement, arrêt et reprise - Windows local + Phone Bridge

Profil : CORE_BRAINLIVE_V18_8_PHONE - sans Neo4j, Graphiti ni Mem0

Ce que V18.8 change

- Les chunks audio de 3 secondes restent tous conservés et transcrits. Qwen reçoit une fenêtre sémantique, pas chaque micro-chunk.
- Les images sont enregistrées immédiatement. Le VLM live évite les images identiques, attend de préférence un silence et reçoit quand même un créneau borné sous parole continue.
- Un GPS inchangé ne relance plus une analyse LLM. Les changements de lieu, libellé, adresse ou mouvement significatif restent des signaux.
- L'assembleur découpe les activités même au même endroit, selon les changements visuels/activité et un plafond de 25 minutes.
- Le feedback d'une intervention est relié au candidate_id, au delivery_id et à un outcome durable fourni à Brain2 pendant le post-stop.

1. Installation sur le PC Windows

Décompresse le ZIP dans C:\MLOmega. Ouvre PowerShell en administrateur dans ce dossier puis exécute :

```
powershell -ExecutionPolicy Bypass -File .\INSTALL_MLOMEGA_V18_8_WINDOWS.ps1 -HfToken "hf_xxx" -PersonId "me"
```

INSTALL installe ou vérifie Python 3.11, FFmpeg, Docker Desktop/WSL2, Qdrant, Ollama, les modèles configurés, la .venv isolée, Silero VAD, faster-whisper, WhisperX, Pyannote, SpeechBrain, embeddings, reranker, SQLite et le Phone Bridge. Il bloque en cas de dépendance indispensable manquante et ne doit afficher PRODUCTION_READY qu'après les probes réelles.

Précondition : le pilote NVIDIA doit déjà fonctionner dans Windows. Vérifie :

```
nvidia-smi
```

Le runtime CUDA est fourni par PyTorch dans .venv. INSTALL ne modifie pas ton Python ou Torch global.

2. Démarrage quotidien

```
cd C:\MLOmega
.\RUN_MLOMEGA_V18_8.ps1 -PersonId me
```

RUN démarre et vérifie Qdrant, Ollama, le Phone Bridge PC sur le port 8766, puis BrainLive. Il attend un heartbeat frais avant RUN_READY.

Élément	Adresse / état
---------	----------------

Phone Bridge PC	http://IP_DU_PC:8766
Qdrant local	http://127.0.0.1:6333
Ollama local	http://127.0.0.1:11434
Dashboard/API éventuel	séparé du Bridge ; ne pas pointer le téléphone sur le dashboard

3. Configuration Android utile

Dans Termux, copie le dossier android du Bridge, installe les outils, puis configure :

```
cd ~/mlomega_phone_bridge/android
bash install_termux_android.sh
cp mlomega_android_config.env.example ~/mlomega_android_config.env
nano ~/mlomega_android_config.env
```

Réglages recommandés :

```
API_BASE="http://IP_DU_PC:8766"
TOKEN="TON_GROS_SECRET"
AUDIO_SECONDS=3
IMAGE_SECONDS=25
GPS_SECONDS=30
REVERSE_GEOCODE=1
ADDRESS_SECONDS=300
ADDRESS_MIN_MOVE_METERS=80
POST_SESSION_STOP=1
DRAIN_UPLOADS_ON_STOP=1
DRAIN_UPLOADS_TIMEOUT_SECONDS=180
```

REVERSE_GEOCODE=1 envoie les coordonnées à Nominatim/OpenStreetMap pour obtenir un intitulé lisible. Active-le seulement si cela te convient.

```
bash start_mlomega_v18_8_android_capture.sh
```

4. Comportement live V18.8

Flux	Règle V18.8
Audio 3 s	Toujours ingéré : VAD, ASR rapide, SpeechBrain, contexte glissant.
Qwen live	Fenêtre audio 45 s, maximum 90 s, ou signal significatif (silence, personne, lieu, activité).
GPS	Un fichier current.json inchangé ne relance pas Qwen.
Image	Raw conservé immédiatement ; VLM live seulement sur changement perceptuel ou rafraîchissement.
Audio continu	Audio prioritaire ; une image attend le silence, l'inactivité, ou au plus 90 s.
Images répétées	Pas de VLM live répété sur quasi-duplicat ;

	toutes les images restent disponibles au deep vision.
--	---

Sur une RTX 3070 8 Go, garde Moondream en live et Qwen3-VL en deep/post-stop. Qwen3-VL est trop lourd pour le live continu sur cette VRAM.

5. Arrêt et close-day

```
.\STOP_MLOMEGA_V18_8.ps1 -PersonId me
```

STOP ne coupe pas seulement BrainLive. Il exécute le chemin protégé :

```
drain Bridge -> drain inbox -> bundles d'activité (max 25 min)
-> deep audio WhisperX + Pyannote + SpeechBrain
-> deep vision Qwen-VL sur <= 12 images représentatives/bundle
-> Brain2 -> longitudinal jour -> coordination -> Life Model -> live-ready
-> manifest de rétention -> purge seulement si zéro pending/retryable/blocked
```

L'arrêt Android via stop_mlomega_v18_8_android_capture.sh vide d'abord le spool local, puis appelle /session/stop. Avec le Bridge lancé par RUN, le même close-day est demandé sur l'ID explicite du service actif.

```
bash stop_mlomega_v18_8_android_capture.sh
```

6. Reprise après crash, timeout ou redémarrage

```
.\RESUME_MLOMEGA_V18_8.ps1 -PersonId me
```

RESUME reprend le même run logique. Les bundles deep audio, images deep vision et conversations Brain2 déjà validés ne sont pas rejoués. Une unité interrompue repart depuis son début ; les raw restent conservés si un stage est retryable_error ou blocked.

7. Interventions et résultat observé

Voir les notifications live en attente :

```
.\venv\Scripts\mlomega-audio.exe brainlive-delivery-queue LIVE_SESSION_ID --status queued
```

Enregistrer le résultat depuis le PC :

```
.\venv\Scripts\mlomega-audio.exe brainlive-delivery-feedback DELIVERY_ID --type acted --source dashboard --note
"Pause faite"
```

Types : delivered, displayed, seen, acted, dismissed, ignored, failed. Le Bridge accepte également un POST authentifié sur /interventions/feedback. Brain2 reçoit ensuite candidate, livraison, feedback et preuve observée ; il ne conclut pas à une causalité sans evidence.

8. Commandes très utiles

```
# Santé / statut
.\DOCTOR_MLOMEGA_V18_8.ps1 -Full -Bridge -Delivery
.\venv\Scripts\mlomega-audio.exe brainlive-status
.\venv\Scripts\mlomega-audio.exe brainlive-inbox-status

# Voix
.\venv\Scripts\mlomega-audio.exe setup-me C:\audios\ma_voix.wav --display-name "Moi" --person-id me
.\venv\Scripts\mlomega-audio.exe voice-pending
.\venv\Scripts\mlomega-audio.exe name-voice UNKNOWN_VOICE_001 max --display-name "Max"

# Audio long hors live
.\venv\Scripts\mlomega-audio.exe flow-once "C:\audios\conversation_1h.wav" --max-chunk-seconds 600

# Mémoire / Brain2
.\venv\Scripts\mlomega-audio.exe brain2-longitudinal-digest --person-id me
.\venv\Scripts\mlomega-audio.exe v14-ask "Qu'est-ce que je suis en train de refaire comme boucle ?" --person-id me
.\venv\Scripts\mlomega-audio.exe v14-interventions --person-id me
```

9. Ce qu'il ne faut pas faire

- Ne lance pas deux services BrainLive en parallèle : un seul propriétaire de session/leases doit exister.
- Ne pointe pas Android vers le Dashboard/API legacy ; utilise le Bridge sur 8766.
- Ne lance pas Qwen3-VL en live sur une RTX 3070 8 Go ; garde-le pour le post-stop.
- Ne purge jamais les dossiers raw ou phone_* manuellement avant une cleanup gate éligible.
- Ne change pas MLOMEGA_DEVICE_ID entre les captures : il sert à dédupliquer les retries téléphone.

Document V18.8.0 - configuration initiale recommandée pour Windows local + RTX 3070 8 Go.